

Procesamiento de imágenes y representación de características

Proyecto final.

Alumno: Rodrigo Gonzaga Sierra[†].

Profesor: Dr. Marco Antonio Aquino Lopez[†].

Centro de Investigación en Matemáticas A. C.[†]

25 de noviembre del 2025



- 1 Introducción
- 2 Metodología y justificación
- 3 PCA, NMF, t-SNE
 - Red Neuronal
- 4 Conclusiones
- 5 Bibliografía

- El análisis de imágenes digitales es una tarea fundamental en visión por computadora, aprendizaje automático y reconocimiento de patrones. Una característica inherente de este tipo de datos es su alta dimensionalidad
- Emplear técnicas de reducción dimensional.

Explorar el uso de técnicas de reducción de dimensión y factorización matricial (como PCA o NMF) aplicadas a imágenes, con el propósito de extraer patrones visuales, comparar representaciones y clasificar imágenes de manera no supervisada.

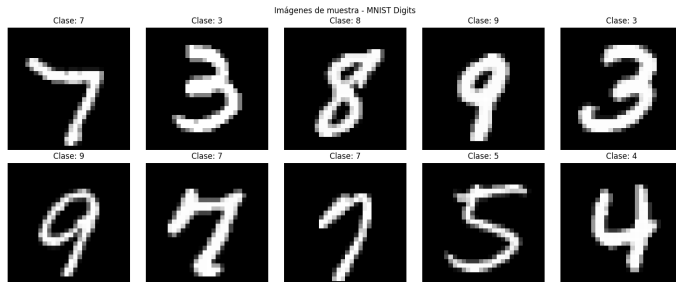



Figure: MNIST-Digits






Figure: Fashion MNIST

airplane




automobile



bird



cat




deer



dog




frog



horse



ship



truck



Figure: Cifar10




Figure: Enter Caption

Una imagen en escala de grises de dimensiones $h \times w$ puede representarse como una matriz:

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1w} \\ x_{21} & x_{22} & \cdots & x_{2w} \\ \vdots & \vdots & \ddots & \vdots \\ x_{h1} & x_{h2} & \cdots & x_{hw} \end{bmatrix}.$$

La vectorización consiste en aplicar la transformación:

$$\text{vec}(X) = (x_{11}, x_{12}, \dots, x_{1w}, x_{21}, \dots, x_{hw})^T \in \mathbb{R}^{hw},$$

que corresponde a aplanar la imagen fila por fila y concatenar sus elementos en un único vector. En el caso de imágenes a color, como CIFAR-10, se dispone de un tensor $h \times w \times 3$. Una estrategia común consiste en convertir la imagen a escala de grises mediante la combinación ponderada:

$$X_{\text{gray}}(i, j) = 0.299 R_{ij} + 0.587 G_{ij} + 0.114 B_{ij},$$

para luego vectorizar la matriz resultante como antes.
Este proceso produce una matriz de datos global:

$$\mathbf{X} \in \mathbb{R}^{n \times d},$$




Figure: PCA




Figure: NMF





Figure: PCA






Figure: PCA




Figure: NMF

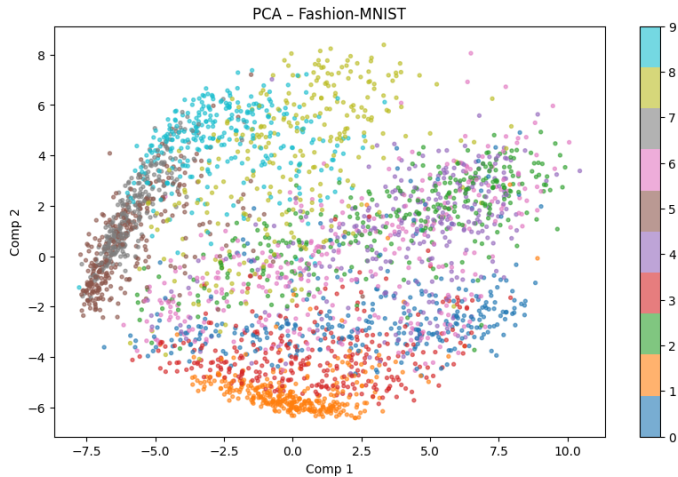


Figure: PCA




Figure: t-SNE




Figure: PCA




Figure: NMF

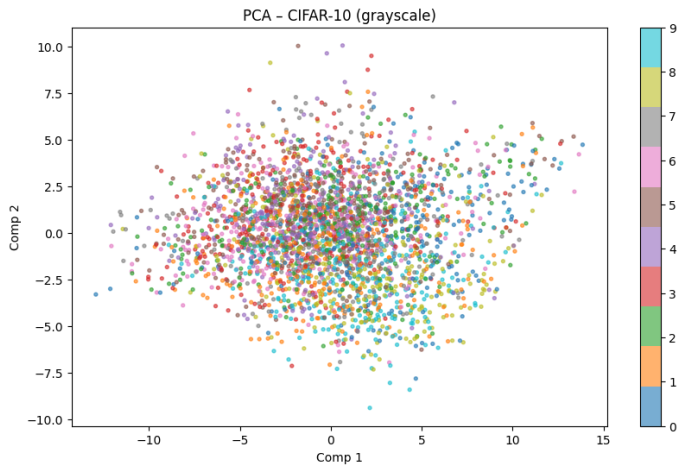


Figure: PCA

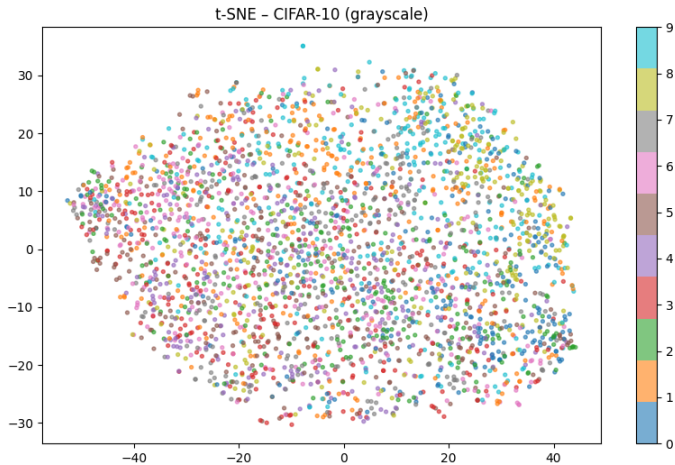


Table: Métricas de evaluación para MNIST, Fashion-MNIST y CIFAR-10 utilizando PCA y NMF

Dataset	Método	Adjusted Rand Score	Silhouette Score
MNIST	PCA	0.358	0.116
	NMF	0.165	0.132
Fashion-MNIST	PCA	0.371	0.222
	NMF	0.248	0.279
CIFAR-10	PCA	0.028	0.090
	NMF	0.020	0.094

Para las bases de datos MNIST:

- Diseñe una red neuronal de una sola capa oculta para la clasificación de las imágenes. Se usa una función de pérdida predefinida.

Para la base de CIFAR-10:

- Se diseñó una red neuronal de una capa oculta completamente conectada de al menos 10,000 neuronas para la clasificación de las imágenes.




Figure: Digits




Figure: Fashion




Figure: CIFAR

Table: Desempeño de las redes neuronales

Modelo	Precisión (%)
MNIST	92.35
Fashion-MNIST	76.68
CIFAR-10 (FC 10,000)	48.74

- Discusión de las bases.
- PCA, NMF , 20-50 Componentes.
- UMAP (Uniform Manifold Approximation and Projection).



Krizhevsky, A., Hinton, G., et al. (2009). Learning multiple layers of features from tiny images.



LeCun, Y. (1998). The mnist database of handwritten digits.
<http://yann.lecun.com/exdb/mnist/>.



Xiao, H., Rasul, K., and Vollgraf, R. (2017). Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms. arXiv preprint arXiv:1708.07747.



Figure: QR repositorio

Agradecimientos:
B. Jesús Salazar García.
Alfredo Bistrain Montiel.

Agradecimientos:
B. Jesús Salazar García.
Alfredo Bistrain Montiel.

¡Gracias por su atención!